

KHOA CÔNG NGHỆ THÔNG TIN TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO QUÁ TRÌNH THAM GIA CUỘC THI HOUSE PRICES - ADVANCED REGRESSION TECHNIQUES

**Dự đoán Giá nhà bằng các Kỹ thuật Hồi quy Machine
Learning.**

Thành viên nhóm 7:

Lê Văn Thông-3123410362

Phan Thanh Thịnh-3123410360

Võ Hoàng Thông-3123410363

GVHD: TS. Đỗ Như Tài

Contents

Tóm tắt:.....	3
CHƯƠNG 1 GIỚI THIỆU	3
1.1 Đặt vấn đề.....	3
1.2 Mục tiêu nghiên cứu.....	3
1.3 Đóng góp chính.....	4
CHƯƠNG 2 PHƯƠNG PHÁP LUẬN.....	4
2.1 Phân tích dữ liệu,phám phá (EDA)	4
2.2 Tiền xử lý dữ liệu	6
2.3 Kỹ thuật đặc trưng	8
2.4 chuẩn hoá dữ liệu.....	9
2.5 Mô hình và thước đo đánh giá.....	9
CHƯƠNG 3 KẾT QUẢ THỰC NGHIỆM	10
3.1 chia dữ liệu huấn luyện.....	10
3.2 So sánh mô hình cơ bản.....	10
3.3 Tối ưu siêu tham số và kết quả cuối cùng	11
CHƯƠNG 4 KẾT LUẬN.....	12
4.1 Kết luận.....	12
4.2 Hạn chế.....	12
4.3 Hướng phát triển.....	12

Tóm tắt:

Dự đoán giá nhà là một bài toán cốt lõi trong lĩnh vực bất động sản và tài chính. Nghiên cứu này tập trung vào việc giải quyết thách thức "House Prices: Advanced Regression Techniques" từ nền tảng Kaggle, sử dụng một bộ dữ liệu phức tạp bao gồm 80 thuộc tính mô tả các khía cạnh khác nhau của bất động sản. Mục tiêu chính của chúng tôi là xây dựng một mô hình học máy có độ chính xác cao để dự đoán giá bán nhà (SalePrice).

Để đạt được mục tiêu này, chúng tôi đã thực hiện một quy trình toàn diện bao gồm: (1) Phân tích dữ liệu khám phá (EDA) để tìm hiểu sâu về sự phân bố và mối quan hệ của dữ liệu; (2) Tiền xử lý dữ liệu kỹ lưỡng, tập trung vào việc xử lý giá trị thiếu và biến đổi các biến; và (3) Kỹ thuật đặc trưng (Feature Engineering) để tạo ra các thuộc tính mới có ý nghĩa. Nhiều mô hình hồi quy đã được xây dựng và đánh giá, bao gồm Lasso Regression, Random Forest, và XGBoost. Các mô hình được đánh giá hiệu quả dựa trên chỉ số Root Mean Squared Logarithmic Error (RMSLE).

Kết quả thực nghiệm cho thấy mô hình XGBoost đạt hiệu suất vượt trội với điểm RMSLE là 0.12485. Chúng tôi cũng phát hiện ra rằng kỹ thuật feature engineering Target Transformation, Missing Data Imputation, New Feature Creation và Categorical Encoding có ảnh hưởng lớn nhất đến việc cải thiện độ chính xác. Bài báo cáo này chứng minh hiệu quả của việc kết hợp tiền xử lý dữ liệu cẩn thận và các thuật toán ensemble mạnh mẽ trong bài toán dự đoán giá.

Keywords (Từ khóa): dự đoán giá nhà, machine learning, hồi quy, feature engineering, XGBoost, Kaggle, RMSLE. (Bạn có thể điều chỉnh các từ khóa này cho phù hợp)

CHƯƠNG 1 GIỚI THIỆU

1.1 Đặt vấn đề

Việc định giá chính xác bất động sản đóng một vai trò then chốt trong nền kinh tế, ảnh hưởng trực tiếp đến các quyết định tài chính quan trọng của cả người mua, người bán, nhà đầu tư và các tổ chức cho vay. Trong bối cảnh thị trường biến động, việc dự đoán giá trị một căn nhà dựa trên các đặc điểm của nó là một bài toán phức tạp nhưng mang lại giá trị thực tiễn cao. Với sự phát triển của khoa học dữ liệu, các mô hình Học máy (Machine Learning) đã cho thấy tiềm năng vượt trội trong việc giải quyết bài toán hồi quy này so với các phương pháp truyền thống.

Bài báo cáo này tập trung vào việc giải quyết thách thức "House Prices: Advanced Regression Techniques" được đặt ra trên nền tảng thi đấu Kaggle. Bộ dữ liệu cung cấp (Ames Housing dataset) là một bộ dữ liệu phức tạp, bao gồm 80 thuộc tính mô tả chi tiết các căn nhà tại Ames, Iowa. Các thuộc tính này bao gồm cả dữ liệu dạng số (như diện tích, số phòng) và dữ liệu dạng phân loại (như vị trí, loại mái nhà, chất lượng hoàn thiện). Sự đa dạng, số lượng thuộc tính lớn, cùng với các vấn đề cố hữu như dữ liệu thiếu (missing values) và dữ liệu ngoại lai (outliers) đặt ra nhiều thách thức trong quá trình xây dựng mô hình.

Mục tiêu chính của nghiên cứu này là xây dựng một mô hình dự đoán có khả năng ước tính giá bán (SalePrice) của các căn nhà một cách chính xác nhất. Chỉ số đánh giá được sử dụng cho bài toán này là Root Mean Squared Logarithmic Error (RMSLE), một thước đo nhấn mạnh vào sai số tương đối và xử lý tốt các dự đoán có giá trị lớn.

Để đạt được mục tiêu này, nhóm đã đề xuất một quy trình làm việc toàn diện, bao gồm ba giai đoạn chính:

Phân tích dữ liệu khám phá (EDA): Tìm hiểu sâu về đặc điểm của bộ dữ liệu, phân phối của biến mục tiêu **SalePrice**, và mối tương quan giữa các thuộc tính.

Tiền xử lý và Kỹ thuật đặc trưng (Preprocessing & Feature Engineering): Xử lý triệt để dữ liệu thiếu, biến đổi các thuộc tính để phù hợp với mô hình, và tạo ra các thuộc tính mới có ý nghĩa để tăng cường sức mạnh dự đoán.

Xây dựng và đánh giá mô hình: Thử nghiệm và so sánh hiệu quả của nhiều thuật toán hồi quy khác nhau, từ các mô hình tuyến tính như Ridge. Đến các mô hình ensemble mạnh mẽ như: Random Forest, XGBoost, LightGBM và kỹ thuật New Feature Creation cùng các kỹ thuật khác.

Cấu trúc của bài báo cáo được tổ chức như sau: Phần 2 trình bày chi tiết về phương pháp luận, mô tả bộ dữ liệu và các kỹ thuật đã sử dụng. Phần 3 trình bày kết quả thực nghiệm và thảo luận về hiệu suất của các mô hình. Cuối cùng, Phần 4 đưa ra kết luận, tóm tắt lại các phát hiện chính và đề xuất các hướng phát triển trong tương lai.

1.2 Mục tiêu nghiên cứu

Nghiên cứu này nhằm các mục tiêu cụ thể sau:

Khảo sát và phân tích bộ dữ liệu Ames Housing để hiểu rõ các thách thức, bao gồm dữ liệu thiếu và phân phối lệch.

Áp dụng và đánh giá hiệu quả của các kỹ thuật tiền xử lý và kỹ thuật đặc trưng (Feature Engineering) trong việc cải thiện hiệu suất mô hình.

Xây dựng, so sánh và đánh giá hiệu suất của nhiều mô hình hồi quy Machine Learning (từ tuyến tính đến ensemble) để tìm ra mô hình tối ưu.

1.3 Đóng góp chính

Đóng góp chính của nghiên cứu này bao gồm:

Trình bày một quy trình (pipeline) hoàn chỉnh và hiệu quả để giải quyết bài toán dự đoán giá nhà.

Chứng minh rằng Kỹ thuật Đặc trưng (ví dụ: tạo TotalSF, Age) và Tiền xử lý (biến đổi log SalePrice) có ảnh hưởng lớn đến độ chính xác cuối cùng.

Đạt được kết quả RMSLE cạnh tranh (0.12485) thông qua việc tối ưu hóa siêu tham số mô hình XGBoost

CHƯƠNG 2 PHƯƠNG PHÁP LUẬN

Chương này trình bày chi tiết về phương pháp luận và kiến trúc giải pháp được chúng tôi thiết kế nhằm giải quyết bài toán dự đoán giá nhà một cách hiệu quả nhất. Đây là trọng tâm của nghiên cứu, minh họa cho một quy trình (pipeline) xử lý dữ liệu hoàn chỉnh, từ dữ liệu thô ban đầu đến một mô hình dự đoán có độ chính xác cao. Để tối ưu hóa kết quả và đảm bảo tính chặt chẽ, phương pháp luận của chúng tôi được xây dựng và chia thành ba giai đoạn cốt lõi, liên kết chặt chẽ với nhau:

Phân tích Dữ liệu Khám phá => Tiền xử lý và Kỹ thuật Đặc trưng => Chuẩn hoá dữ liệu => Đánh giá mô hình.

Các phần tiếp theo sẽ đi sâu vào từng giai đoạn, làm rõ các kỹ thuật cụ thể đã được áp dụng và cơ sở lý luận đằng sau mỗi lựa chọn.

2.1 Phân tích dữ liệu, khám phá (EDA)

Bộ dữ liệu được lấy từ: <https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques>

Với 80 cột và 1460 dòng với 43 cột là thuộc tính categorical.

Sau khi đánh giá dữ liệu có thể thấy được:

Một số cột thiếu dữ liệu:

LotFrontage(kiểu float) chỉ có 1201 giá trị, bị thiếu 259.


GarageYrBlt (năm xây dựng) có 1379 giá trị, thiếu 81 giá trị.

MasVnrArea (Diện tích ốp gạch) có 1452 giá trị, bị thiếu 8 giá trị.

Một số cột phân phối bị lệch khi mean của SalePrice là 180921 lớn hơn trung vị 163000 cho thấy cột này đang bị lệch phải. LotArea: mean (10,516) > median (9,478). Có một vài lô đất rất lớn. GrLivArea: mean (1515) > median (1464). Có một vài ngôi nhà diện tích rất lớn. MasVnrArea: mean (103) > median (0). Bị lệch nghiêm trọng, vì hầu hết các nhà có giá trị ở trung vị là 0. Nhiều cột có min, 25% và 50% (median) đều bằng 0. 2ndFlrSF: 50% là 0, có nghĩa là hơn một nửa số nhà trong tập dữ liệu này là nhà 1 tầng (không có lầu 2). PoolArea: mean rất nhỏ (2.7) và 50% là 0. Điều này cho thấy gần như không có nhà nào có hồ bơi. Các biến khác: WoodDeckSF, OpenPorchSF, EnclosedPorch, ScreenPorch, BsmtFinSF2, LowQualFinSF, MiscVal... đều có rất nhiều giá trị 0. Đây không phải là dữ liệu xấu. Nó có nghĩa là "0" là một giá trị hợp lệ, mang ý nghĩa là "không có" (không có hiên, không có hồ bơi, v.v.).

Đến với việc phân tích dữ liệu:

Với biến mục tiêu SalePrice ta có sơ đồ phân phối:




Quan sát biểu đồ histogram, ta thấy SalePrice không tuân theo phân phối chuẩn mà có xu hướng lệch phải (Right-skewed) với hệ số Skewness lên tới 1.88. Dữ liệu tập trung dày đặc ở khoảng giá 100k-180k USD, nhưng tồn tại một "đuôi dài" các giá trị ngoại lai (outliers) ở mức giá cao (>500k USD).

Vấn đề: Sự phân phối lệch này vi phạm giả định về tính chuẩn (Normality) của các mô hình hồi quy tuyến tính và khiến mô hình bị ảnh hưởng mạnh bởi các giá trị ngoại lai, dẫn đến hiệu suất dự đoán kém ổn định.

Giải pháp: Để khắc phục, chúng tôi áp dụng kỹ thuật Biến đổi Logarit (Log Transformation) cụ thể là hàm $\log(1+x)$. Kỹ thuật này giúp co ngắn khoảng cách của các giá trị lớn, đưa phân phối về dạng gần chuẩn (Normal Distribution), giúp mô hình hồi quy hoạt động hiệu quả và hội tụ tốt hơn.

Với ma trận tương quan giữa các biến số sau:




Ta có thể tìm được những biến tương quan mạnh với SalePrice.

Dưới đây là 10 cột có tương quan cao nhất với SalePrice:

SalePrice	1.000000
OverallQual	0.790982
GrLivArea	0.708624
GarageCars	0.640409
GarageArea	0.623431
TotalBsmtSF	0.613581
1stFlrSF	0.605852
FullBath	0.560664
TotRmsAbvGrd	0.533723
YearBuilt	0.522897

Nhận xét OverallQual (Chất lượng tổng thể): 0.79 Đây là đặc trưng quan trọng nhất! Nó có mối quan hệ tuyến tính mạnh nhất với giá bán. Chỉ riêng việc biết chất lượng tổng thể của ngôi nhà đã cho bạn một chỉ báo rất tốt về giá của nó. GrLivArea (Diện tích sống): 0.71. Đặc trưng quan trọng thứ hai. Rất logic, nhà càng rộng thì giá càng cao. GarageCars & GarageArea (Số chỗ đậu xe & Diện tích Garage): 0.64 & 0.62. Garage lớn (chứa được nhiều xe) là một yếu tố dự đoán giá rất tốt. (Hai biến này có thể bị tương quan cao với nhau, gọi là đa cộng tuyến). TotalBsmtSF & 1stFlrSF (Tổng diện tích tầng hầm & Tầng 1): 0.61 & 0.60. Tổng diện tích sử dụng (bao gồm cả tầng hầm) ảnh hưởng lớn đến giá trị. Các Đặc trưng Quan trọng (Tương quan > 0.5): FullBath (Số phòng tắm): 0.56 TotRmsAbvGrd (Tổng số phòng): 0.53. YearBuilt (Năm xây dựng): 0.52. Nhà càng mới (năm xây dựng càng lớn) thì giá càng cao.

Biểu đồ theo chất lượng tổng thể:



Nhà có chất lượng tổng thể (OverallQual) càng cao thì giá bán (SalePrice) càng cao. Điều này hoàn toàn khớp với chỉ số tương quan 0.79 mà ta tìm thấy trước đó. Khi nhìn vào OverallQual từ 1-3 hộp rất dẹt cho thấy với chất lượng thấp này thì SalePrice khá tương đồng nhau. OverallQual từ 7-10 hộp khoảng giá khá rộng giá cả lúc này phân bố có giá chênh nhau nhiều. Nhìn vào outlier ở OverallQual thấp thì giá ổn định ít outlier so với cao.

2.2 Tiền xử lý dữ liệu

Các cột có giá trị bị thiếu nhưng ý nghĩa không có như (Alley, FireplaceQu, PoolQC...) đều sẽ được điền các giá trị None Vào.

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Utilities	...	PoolArea	PoolQC	Fence	MiscFeature	MiscVal	MoSold	YrSold	SaleType	SaleCondition	SalePrice
0	1	60	RL	65.0	8450	Pave	None	Reg	Lvl	AllPub	...	0	None	None	None	0	2	2008	WD	Normal	208500
1	2	20	RL	80.0	9600	Pave	None	Reg	Lvl	AllPub	...	0	None	None	None	0	5	2007	WD	Normal	181500
2	3	60	RL	68.0	11250	Pave	None	IR1	Lvl	AllPub	...	0	None	None	None	0	9	2008	WD	Normal	223500
3	4	70	RL	60.0	9550	Pave	None	IR1	Lvl	AllPub	...	0	None	None	None	0	2	2006	WD	Abnorml	140000
4	5	60	RL	84.0	14260	Pave	None	IR1	Lvl	AllPub	...	0	None	None	None	0	12	2008	WD	Normal	250000
5	6	50	RL	85.0	14115	Pave	None	IR1	Lvl	AllPub	...	0	None	MnPrv	Shed	700	10	2009	WD	Normal	143000
6	7	20	RL	75.0	10084	Pave	None	Reg	Lvl	AllPub	...	0	None	None	None	0	8	2007	WD	Normal	307000
7	8	60	RL	NaN	10382	Pave	None	IR1	Lvl	AllPub	...	0	None	None	Shed	350	11	2009	WD	Normal	200000
8	9	50	RM	51.0	6120	Pave	None	Reg	Lvl	AllPub	...	0	None	None	None	0	4	2008	WD	Abnorml	129900
9	10	190	RL	50.0	7420	Pave	None	Reg	Lvl	AllPub	...	0	None	None	None	0	1	2008	WD	Normal	118000

Trong bộ dữ liệu này, giá trị bị thiếu (NA) ở các cột này không thực sự có nghĩa là "không biết" (missing data), mà nó mang ý nghĩa là "không có" (absence of a feature).

Ví dụ: Alley (Hẻm) bị thiếu có nghĩa là "Không có lối vào hẻm". PoolQC (Chất lượng hồ bơi) bị thiếu có nghĩa là "Không có hồ bơi". Việc điền giá trị chuỗi "None" (hoặc "No Alley", "No Pool") sẽ biến đổi chúng thành một hạng mục (category) rõ ràng, giúp mô hình học máy hiểu đúng bản chất của dữ liệu thay vì coi đó là một giá trị bị mất cần suy đoán.

Các cột bị thiếu như MasVnrArea (Diện tích tường ốp gạch) người ta bỏ trống thì điền các giá trị bị thiếu bằng 0 thì sẽ hợp lý hơn.


MasVnrArea missing: 0

	MasVnrArea
count	1460.000000
mean	103.117123
std	180.731373
min	0.000000
25%	0.000000
50%	0.000000
75%	164.250000
max	1600.000000

Tương tự như trên, MasVnrArea (Diện tích ốp gạch) bị thiếu rất có thể đi kèm với cột MasVnrType (Loại gạch ốp) là "None". Nếu một ngôi nhà không có ốp gạch (MasVnrType = None), thì diện tích ốp gạch (MasVnrArea) của nó đương nhiên là 0. Do đó, điền giá trị 0 là cách xử lý logic và chính xác nhất cho trường hợp này, phản ánh đúng thực tế của ngôi nhà. Với giá trị LotFrontage ta điền các giá trị bị thiếu bằng giá trị median và nhóm theo từng Neighborhood.

	LotFrontage Trước xử lý	LotFrontage Sau xử lý
count	1201.000000	1460.000000
mean	70.049958	70.199658
std	24.284752	22.431902
min	21.000000	21.000000
25%	59.000000	60.000000
50%	69.000000	70.000000
75%	80.000000	80.000000
max	313.000000	313.000000

LotFrontage (Mặt tiền tiếp giáp với đường) là một giá trị số liên tục. Việc chỉ điền giá trị trung bình (mean) hoặc trung vị (median) *toàn cục* (của tất cả các ngôi nhà) có thể không chính xác, vì mặt tiền thường phụ thuộc nhiều vào vị trí. Chiến lược này giả định rằng các ngôi nhà trong cùng một khu (Neighborhood) có xu hướng có đặc điểm mặt tiền tương tự nhau. Đây là một giả định rất hợp lý. Việc sử dụng median (trung vị) thay vì mean (trung bình) cũng là một lựa chọn tốt, vì median ít bị ảnh hưởng bởi các giá trị ngoại lệ (ví dụ: một vài ngôi nhà có mặt tiền quá lớn hoặc quá nhỏ trong khu đó). Sau đó ta xử lý phân phối lệch chuẩn cho biến mục tiêu SalePrice, lệch phải (sử dụng kỹ thuật biến đổi logTransformation):



Dữ liệu sau khi xử lý phân phối lệch chuẩn đã khá ổn định để sử dụng.

Tiếp tục mã hoá (Encoding) các biến phân loại (object) thực hiện đồng bộ cột và One hot encoding.

BsmtFinSF1	...	SaleType_ConLI	SaleType_ConLw	SaleType_New	SaleType_Oth	SaleType_WD	SaleCondition_AdjLand	SaleCondition_Alloca	SaleCondition_Family	SaleCondition_Normal	SaleCondition_Partial
706	...	False	False	False	False	True	False	False	False	True	False
978	...	False	False	False	False	True	False	False	False	True	False
486	...	False	False	False	False	True	False	False	False	True	False
216	...	False	False	False	False	True	False	False	False	False	False
655	...	False	False	False	False	True	False	False	False	True	False

2.3 Kỹ thuật đặc trưng

	TotalBsmtSF	1stFlrSF	2ndFlrSF	TotalSF
0	-0.459303	-0.793434	1.161852	-0.001277
1	0.466465	0.257140	-0.795163	-0.052407
2	-0.313369	-0.627826	1.189351	0.169157
3	-0.687324	-0.521734	0.937276	-0.114493
4	0.199680	-0.045611	1.617877	0.944631

Giảm đa cộng tuyến (Reduces Multicollinearity): Các cột 1stFlrSF, 2ndFlrSF, TotalBsmtSF gần như chắc chắn có tương quan cao với nhau (nhà to thì tầng 1 to, tầng 2 cũng to). Việc giữ cả 3 cột này có thể gây ra hiện tượng đa cộng tuyến, làm cho mô hình (đặc biệt là hồi quy tuyến tính) trở nên không ổn định. Tạo quan hệ tuyến tính (Creates Linearity): Giá nhà (SalePrice) có khả năng tương quan *tuyến tính* (đường thẳng) với TotalSF cao hơn nhiều so với khi tương quan với 3 cột riêng lẻ. Điều này giúp các mô hình tuyến tính hoạt động hiệu quả hơn.

Cột TotalSF (tổng diện tích sử dụng) được xác định bằng cách tính tổng 1stFlrSF (diện tích tầng một) và 2ndFlrSF (diện tích tầng 2) với TotalBsmtSF (tổng diện tích tầng hầm) đối với mô hình, đây là 3 thông tin độc lập. Rõ ràng, giá nhà phụ thuộc vào tổng diện tích, nhưng mô hình không tự biết phép cộng Cột TotalSF này sẽ là một đặc trưng cực kỳ mạnh để dự đoán SalePrice.

	FullBath	HalfBath	BsmtFullBath	BsmtHalfBath	TotalBathrooms
0	0.789741	1.227585	1.107810	-0.241061	1.642256
1	0.789741	-0.761621	-0.819964	3.948809	0.368581
2	0.789741	1.227585	1.107810	-0.241061	1.642256
3	-1.026041	-0.761621	1.107810	-0.241061	-0.268257
4	0.789741	1.227585	1.107810	-0.241061	1.642256

Giảm chiều dữ liệu (Dimensionality Reduction): Tôi đã biến 4 cột thành 1 cột. Điều này giúp mô hình đơn giản hơn, giảm nguy cơ overfitting (học vẹt) và tăng tốc độ huấn luyện. Logic nghiệp vụ: Mô hình sẽ không tự biết rằng HalfBath chỉ đáng giá bằng 0.5 FullBath. Bằng cách gán trọng số này, mô hình đã được dạy logic của thị trường bất động sản, giúp nó hội tụ nhanh và chính xác hơn với công thức: $\text{TotalBathrooms} = \text{FullBath} + 0.5 * \text{HalfBath} + \text{BsmtFullBath} + 0.5 * \text{BsmtHalfBath}$.

Công thức này đánh giá sự tiện nghi của căn nhà một cách chính xác hơn giúp cải thiện về việc xác định giá nhà

	YrSold	YearBuilt	Age
0	2008	2003	5
1	2007	1976	31
2	2008	2001	7
3	2006	1915	91
4	2008	2000	8

Cột 3 Age(Age ở đây chính là tuổi của căn nhà) tạo đặc trưng này giúp mô hình hiểu rõ về độ cũ của căn nhà hơn, Con số 1990 bản thân nó không có nhiều ý nghĩa. Ý nghĩa thực sự là "căn nhà này cũ bao nhiêu năm khi được bán,nếu tạo đặc trưng Age = YrSold – YearBuilt kết quả Con số 20 (20 tuổi) ở cột Age là một tín hiệu trực tiếp, rõ ràng cho mô hình hiểu về "độ cũ" của căn nhà, hơn là con số 1990.

2.4 Chuẩn hoá dữ liệu

Tất cả các biến số được chuẩn hoá bằng StandardScaler để đưa về cùng thang đo (mean = 0, std = 1). Việc này giúp mô hình hồi quy học ổn định, tránh việc các đặc trưng có giá trị lớn chi phối kết quả.Tập test được chuẩn hoá bằng cùng thông số của tập train để đảm bảo tính nhất quán.

	mean	std
Id	0.000000e+00	1.000343
MSSubClass	-8.455945e-17	1.000343
LotFrontage	2.920039e-16	1.000343
LotArea	-5.840077e-17	1.000343
OverallQual	1.387018e-16	1.000343
OverallCond	3.540547e-16	1.000343
YearBuilt	1.046347e-15	1.000343
YearRemodAdd	4.496860e-15	1.000343
MasVnrArea	-3.893385e-17	1.000343
BsmtFinSF1	-2.433366e-17	1.000343

2.5 Mô hình và thước đo đánh giá.

Chúng tôi đã sử dụng các mô hình để thử nghiệm như : mô hình tuyến tính Ridge Regrestion, RandomForest, XGBoost, LightGBM.

Chỉ số đánh giá chính thức của cuộc thi là Root Mean Squared Logarithmic Error (RMSLE). Để tối ưu hóa trực tiếp chỉ số này, chúng tôi đã áp dụng kỹ thuật biến đổi log (log transformation) cho biến mục tiêu SalePrice ở bước tiền xử lý. Khi đó, việc tối ưu hóa chỉ số RMSE (Root Mean Squared Error) trên dữ liệu đã biến đổi log sẽ tương đương về mặt toán học với việc tối ưu hóa RMSLE trên dữ liệu gốc. Do đó, trong quá trình huấn luyện, chúng tôi sử dụng RMSE làm thước đo chính để đánh giá mô hình:

RMSE (Root Mean Squared Error) đo độ lệch trung bình giữa giá trị dự đoán và giá trị thật.

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$$

- Khi mô hình dự đoán gần với giá trị thật → sai số nhỏ → RMSE nhỏ.
- Khi mô hình dự đoán sai lệch nhiều → sai số lớn → RMSE lớn.

R^2 (Coefficient of Determination) đo mức độ mô hình giải thích được biến mục tiêu (SalePrice).

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

- SS_{res} : tổng bình phương sai số (residual sum of squares)
- SS_{tot} : tổng bình phương tổng thể (total sum of squares)

CHƯƠNG 3 KẾT QUẢ THỰC NGHIỆM

Sau khi hoàn thành việc tiền xử lý, làm sạch dữ liệu và trích xuất các đặc trưng quan trọng ở Chương 2, trong chương này, chúng tôi sẽ tiến hành đưa bộ dữ liệu vào huấn luyện thực nghiệm trên các mô hình học máy. Mục tiêu là tìm ra mô hình tối ưu nhất có khả năng dự đoán chính xác giá nhà (SalePrice).

Quá trình thực nghiệm sẽ bao gồm ba giai đoạn chính: phân chia dữ liệu, đánh giá các mô hình cơ sở (Baseline models) và tối ưu hóa siêu tham số (Hyperparameter Tuning). Hiệu suất của các mô hình sẽ được đánh giá và so sánh dựa trên chỉ số Sai số căn quân phương (RMSE) trên tập kiểm định.

Như đã đề cập trong mục 2.5 thước đo chính thức được sử dụng để so sánh hiệu suất giữa các mô hình là RMSE (Root Mean Squared Error) trên dữ liệu đã biến đổi log. Giá trị RMSE càng nhỏ thể hiện mô hình càng chính xác và ít có các sai số dự đoán lớn.

3.1 Chia dữ liệu huấn luyện

Để có thể đánh giá hiệu suất của mô hình một cách khách quan và kiểm soát hiện tượng quá khớp (overfitting), chúng tôi đã phân chia bộ dữ liệu huấn luyện (lấy từ train.csv) thành hai tập con riêng biệt theo tỷ lệ 80/20.

Tập Huấn luyện (Training Set): Chiếm 80% dữ liệu gốc. Đây là tập dữ liệu mà mô hình sẽ "học" (fit) trong quá trình huấn luyện.

Tập Kiểm định (Validation Set): Chiếm 20% dữ liệu còn lại. Tập này được giữ riêng hoàn toàn và mô hình không "học" trên đó. Nó đóng vai trò là dữ liệu "lạ" (unseen data) dùng để: Đánh giá hiệu suất thực tế của mô hình, phát hiện sớm hiện tượng quá khớp (khi lỗi trên tập huấn luyện giảm nhưng lỗi trên tập kiểm định lại tăng), làm cơ sở để tinh chỉnh các siêu tham số (Hyperparameter Tuning).

Phép chia này được thực hiện bằng cách sử dụng hàm `train_test_split` từ thư viện Scikit-learn. Một giá trị `random_state` cụ thể (ví dụ: `random_state=42`) đã được thiết lập để đảm bảo rằng phép chia dữ liệu luôn nhất quán, cho phép bất kỳ ai cũng có thể tái tạo lại (reproducible) chính xác kết quả của nghiên cứu này.

```
Train size: (1168, 262)
Validation size: (292, 262)
```

3.2 So sánh mô hình cơ bản

Chúng tôi đã huấn luyện 4 mô hình cơ sở. Kết quả RMSE trên tập kiểm định được trình bày ở bảng sau:

	Model	RMSE
3	LightGBM	0.138569
2	XGBoost	0.139023
0	Ridge	0.139024
1	RandomForest	0.147560

Dựa vào điểm RMSE sơ bộ trong bảng, LightGBM (0.1386) và XGBoost (0.1390) là hai mô hình tốt nhất. Mặc dù LightGBM có RMSE thấp hơn một chút, chúng tôi chọn XGBoost để tối ưu hóa sâu hơn do XGBoost (eXtreme Gradient Boosting) là một lựa chọn tiêu chuẩn trong các cuộc thi Kaggle về dữ liệu dạng bảng vì nó cực kỳ mạnh mẽ, có khả năng xử lý dữ liệu thiếu, tích hợp sẵn cơ chế điều chuẩn (regularization) để chống quá khớp (overfitting), và được tối ưu hóa về tốc độ.

3.3 Tối ưu siêu tham số và kết quả cuối cùng

Chúng tôi sử dụng Optuna với kỹ thuật Bayesian optimization để tìm bộ siêu tham số tối ưu cho XGBoost. Quá trình tối ưu hóa tìm được bộ tham số tốt nhất với điểm RMSE trung bình (trên 5-fold cross-validation) là **0.12427**. Với việc tìm được siêu tham số như sau :

```
n_estimators: 795
learning_rate: 0.041781133811210534
max_depth: 4
subsample: 0.9004238636768309,
colsample_bytree: 0.8861701514544139
gamma: 0.0007839147453102702
min_child_weight: 3
có best RMSE (CV): 0.12426823835659428.
```

Và sau khi huấn luyện mô hình tốt nhất bằng siêu tham số ta đạt được như sau:

Hiệu suất mô hình XGBoost:


RMSE (Train): 0.03192.

RMSE (Validation): 0.03301.

R^2 (Train): 0.9936.

R^2 (Validation): 0.9942.

Mô hình có hiệu suất cao, R^2 (Train) gần bằng R^2 (Validation) cho thấy mô hình không overfit.



Các điểm màu xanh (giá dự đoán vs giá thực tế) nằm rất sát với đường đỏ. Điều này chứng tỏ mô hình dự đoán rất chính xác, vì sai lệch giữa giá dự đoán và giá thật là rất nhỏ. Chỉ vài điểm lệch nhẹ ở vùng giá cao, có thể do dữ liệu ít ở vùng này (dữ liệu cao giá hiếm khi gặp). Sau khi lưu mô hình lại và sử dụng mô hình đó để dự đoán trên dữ liệu test và tạo file nộp bài(submission file) cho kaggle kết quả ta đạt được 0.12485 điểm.

701	Thanh Thịnh Phan		0.12485	10	17m
Your Best Entry! Your most recent submission scored 0.12485, which is an improvement over your previous score of 0.12671. Great job! Tweet this					
702	Tanmay Agarwal09		0.12485	1	15d

CHƯƠNG 4 KẾT LUẬN

4.1 Kết luận

Nghiên cứu này đã trình bày một quy trình toàn diện để giải quyết bài toán dự đoán giá nhà trong cuộc thi "House Prices: Advanced Regression Techniques" của Kaggle. Mục tiêu chính là xây dựng được mô hình hồi quy với độ chính xác cao nhất, đo bằng chỉ số RMSLE.

Qua quá trình Phân tích Dữ liệu Khám phá (EDA), chúng tôi đã xác định được các phát hiện then chốt: (1) Biến mục tiêu SalePrice bị lệch phải nghiêm trọng, và (2) Các thuộc tính như OverallQual (Chất lượng tổng thể) và GrLivArea (Diện tích sinh hoạt) có tương quan mạnh nhất với giá bán.

Để giải quyết các thách thức này, chúng tôi đã áp dụng các kỹ thuật tiền xử lý và Kỹ thuật Đặc trưng (Feature Engineering) một cách cẩn thận. Kỹ thuật quan trọng nhất là **biến đổi log (log1p)** cho biến SalePrice để chuẩn hóa phân phối, điều này trực tiếp giúp tối ưu hóa chỉ số RMSLE. Đồng thời, các đặc trưng mới như TotalSF (Tổng diện tích) và Age (Tuổi nhà) đã được tạo ra, và 43 biến categorical đã được mã hóa (encoding) hiệu quả.

Sau khi so sánh hiệu suất của 10 mô hình Machine Learning khác nhau, chúng tôi nhận thấy các mô hình ensemble (như XGBoost, LightGBM) cho kết quả vượt trội so với các mô hình tuyến tính cơ bản. Mô hình cho hiệu quả cao nhất là **XGBoost**, kết hợp sức mạnh của nhiều mô hình đơn lẻ. Bằng cách sử dụng **Optuna** với kỹ thuật Bayesian Optimization để tinh chỉnh siêu tham số, mô hình Stacked cuối cùng đã đạt được điểm Validation RMSLE là 0.126.

Kết quả của bài tập này khẳng định rằng việc đầu tư thời gian vào EDA và Feature Engineering, kết hợp với các thuật toán ensemble mạnh mẽ và tối ưu hóa siêu tham số, là chìa khóa để xây dựng các mô hình dự đoán chính xác và hiệu quả.

4.2 Hạn chế.

Mặc dù đạt được kết quả tốt, nghiên cứu này có một số hạn chế:

Các đặc trưng được tạo ra chủ yếu dựa trên phân tích trực quan, chưa áp dụng các phương pháp tạo đặc trưng tự động (automated feature engineering). Mô hình XGBoost, tuy hiệu quả, nhưng là một mô hình "hộp đen" (black-box), thiếu khả năng diễn giải so với các mô hình tuyến tính.

4.3 Hướng phát triển.

Hướng phát triển trong tương lai có thể bao gồm: Áp dụng các kỹ thuật giải thích mô hình (ví dụ: SHAP, LIME) để hiểu rõ hơn đóng góp của từng đặc trưng. Khảo sát các kiến trúc Deep Learning (ví dụ: mạng nơ-ron) cho dữ liệu dạng bảng để so sánh hiệu suất. Xây dựng mô hình Stacked hoặc Blending kết hợp sức mạnh của nhiều mô hình.