

INTRODUCTION:

Problem definition:

- House Prices – Advanced Regression Techniques (Giá nhà – Kỹ thuật hồi quy nâng cao)
- Dự đoán giá bán của các căn nhà dựa trên nhiều đặc trưng mô tả về cấu trúc, chất lượng, diện tích, tiện nghi và vị trí.

Challenge:

- Dữ liệu chứa hơn 80 biến đầu vào với nhiều dạng khác nhau (số, phân loại, nhị phân).
- Có nhiều giá trị thiếu và dữ liệu không đồng nhất.
- Một số đặc trưng có tương quan cao hoặc không có ý nghĩa rõ ràng.
- Cần chọn mô hình hồi quy thích hợp và tối ưu siêu tham số để đạt hiệu suất cao.

DATASET:

House Prices - Advanced Regression Techniques

<https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques/data>

- train.csv** - the training set
- test.csv** - the test set
- data_description.txt** - full description of each column, originally prepared by Dean De Cock but lightly edited to match the column names used here
- sample_submission.csv** - a benchmark submission from a linear regression on year and month of sale, lot square footage, and number of bedrooms

PROPOSED METHOD:

Dữ liệu vào → Phân tích khám phá dữ liệu → Tiền xử lý dữ liệu



Đánh giá mô hình ← Lựa chọn và huấn luyện mô hình

KEY MODULES:

Data Preprocessing


- Xử lý giá trị thiếu (mean, median, mode).
- Mã hóa biến phân loại (One-Hot, Label Encoding).
- Chuẩn hóa hoặc scale dữ liệu.
- Phát hiện & xử lý outlier nếu cần.

Feature Engineering

- Tạo đặc trưng mới có ý nghĩa (ví dụ: tuổi nhà = năm bán – năm xây).
- Chọn đặc trưng quan trọng dựa trên tương quan hoặc độ quan trọng mô hình.
- Giảm chiều dữ liệu (PCA, Feature Selection).

DATA ANALYSIS:


Phân tích biến mục tiêu: SalePrice



10 cột tương quan cao nhất

SalePrice	1.000000
OverallQual	0.790982
GrLivArea	0.708624
GarageCars	0.640409
GarageArea	0.623431
TotalBsmtSF	0.613581
1stFlrSF	0.605852
FullBath	0.560664
TotRmsAbvGrd	0.533723
YearBuilt	0.522897

Ma trận tương quan giữa các biến số



EXPERIMENTS AND RESULTS:

Dữ liệu đầu vào: train_clean.csv và test_clean.csv, chứa các đặc trưng đã được làm sạch và chuẩn hóa
Kích thước dữ liệu:

- Train: 1,460 mẫu × 264 đặc trưng
- Test: 1,459 mẫu × 263 đặc trưng

Dữ liệu được chia thành:

- 80% train
 - 20% validation
- nhằm đảm bảo đánh giá khách quan và tránh overfitting.

Lựa chọn và huấn luyện mô hình:

Mô hình	RMSE (Validation)
Ridge	0.13902
RandomForest	0.14756
XGBoost	0.13902
LightGBM	0.13857

→ LightGBM đạt RMSE thấp nhất (0.1386), nhưng XGBoost có độ ổn định cao và khả năng tối ưu tốt, nên được chọn làm mô hình chính để tinh chỉnh.

Đánh giá mô hình bằng các chỉ số RMSE, MAE, R²

RMSE (Root Mean Squared Error) đo độ lệch trung bình giữa giá trị dự đoán và giá trị thật.

$$RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$$


- Khi mô hình dự đoán gần với giá trị thật → sai số nhỏ → RMSE nhỏ.
- Khi mô hình dự đoán sai lệch nhiều → sai số lớn → RMSE lớn.

R² (Coefficient of Determination) đo mức độ mô hình giải thích được biến mục tiêu (SalePrice).

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

- SS_{res}: tổng bình phương sai số (residual sum of squares)
- SS_{tot}: tổng bình phương tổng thể (total sum of squares)

Biểu đồ so sánh giữa thực tế và dự đoán



Kết quả trên Kaggle:

